

UNIVERSIDADE FEDERAL DO MARANHÃO

Curso de Ciência da Computação

Disciplina de Processamento de Imagem

Detecção e Quantificação de Doenças em Folhas de Plantas

utilizando Técnicas Clássicas de Processamento de Imagem

Documento de Planejamento e Execução do Projeto

Início: 05 de maio de 2026 • Entrega: 06 de julho de 2026 • Duração: 9 semanas

1. Visão Geral do Projeto

Doenças em plantas representam uma ameaça significativa à produção agrícola global. Segundo levantamentos da literatura especializada, perdas causadas por patógenos de origem fúngica, bacteriana e viral impactam diretamente a qualidade e o volume das safras, gerando prejuízos econômicos bilionários. No Brasil, esse cenário é especialmente crítico dada a extensão do agronegócio nacional.

O método tradicional de diagnóstico de doenças em plantas é feito por inspeção visual humana, o que é lento, sujeito a erros e dependente da experiência do especialista. Sistemas automáticos de detecção baseados em processamento de imagem surgem como alternativa viável para tornar esse diagnóstico mais rápido, reproduzível e acessível.

Este projeto propõe o desenvolvimento de um sistema de análise de imagens de folhas de plantas capaz de detectar a presença de doenças e quantificar a severidade da infecção, utilizando exclusivamente técnicas clássicas de processamento de imagem. Não serão utilizadas redes neurais ou qualquer forma de aprendizado profundo. Todo o pipeline é construído sobre operações de PI implementadas com a biblioteca OpenCV em Python.

2. Objetivos

2.1 Objetivo Geral

Desenvolver um pipeline computacional baseado em técnicas clássicas de processamento de imagem para detectar a presença de doenças em folhas de plantas e quantificar automaticamente a severidade da lesão, classificando-a em níveis de gravidade.

2.2 Objetivos Específicos

- Implementar um módulo de pré-processamento que prepare as imagens para análise (carregamento, conversão de espaço de cor, redução de ruído).
- Implementar a segmentação automática da folha, isolando-a do fundo da imagem.
- Implementar a detecção e segmentação das regiões lesionadas dentro da área da folha.
- Calcular a porcentagem da área afetada em relação à área total da folha.
- Classificar a severidade da doença em quatro níveis: Saudável, Leve, Moderada e Grave.
- Gerar visualizações interpretadas dos resultados: máscara de lesão sobreposta à imagem original e histograma de cores.
- Validar o pipeline com imagens do dataset PlantVillage, comparando resultados visuais com os rótulos originais.

3. Fundamentação Técnica

3.1 Por que Processamento de Imagem Clássico?

A literatura especializada demonstra que técnicas clássicas de PI são eficazes para esse problema. Singh & Misra (2021) propõem um pipeline que converte imagens RGB para HSV, extrai características de cor e textura via GLCM e calcula contornos para determinar a área afetada, sem uso de redes neurais. De modo similar, o trabalho de Mohanty et al. (2016), que introduziu o dataset PlantVillage, realizou a própria segmentação das folhas utilizando análise de componentes de cor, luminosidade e saturação nos espaços Lab e HSB — técnicas inteiramente clássicas.

A abordagem clássica oferece vantagens importantes no contexto deste projeto: é interpretável (cada decisão tem justificativa explícita no espaço de pixels), não requer GPU nem grandes volumes de dados rotulados para treinar modelos, e é implementada com ferramentas estáveis e amplamente documentadas como OpenCV.

3.2 Espaço de Cor HSV

O espaço de cor HSV (Hue, Saturation, Value) é fundamental para este projeto. Diferente do RGB, onde informação de cor e luminosidade estão misturadas nos três canais, o HSV separa a informação cromática (matiz — H) da informação de brilho (V), tornando a segmentação por cor muito mais robusta a variações de iluminação.

No OpenCV, o canal H varia de 0 a 179 (não 0–360). Folhas saudáveis concentram-se nos tons verdes ($H \approx 35\text{--}85$). Regiões doentes, dependendo da patologia, apresentam tons amarelos ($H \approx 20\text{--}35$) ou marrons/avermelhados ($H \approx 0\text{--}20$ e $160\text{--}179$). Essa distinção no canal H é a base da segmentação de lesões neste projeto.

3.3 Morfologia Matemática

Operações morfológicas são aplicadas sobre imagens binárias (máscaras) para refinar os resultados da segmentação. As principais operações utilizadas serão: erosão (remove pequenos ruídos), dilatação (preenche buracos na máscara), abertura (erosão seguida de dilatação) e fechamento (dilatação seguida de erosão, une regiões próximas). Todas implementadas via `cv2.morphologyEx()`.

3.4 Referências de Embasamento

- MOHANTY, S. P.; HUGHES, D. P.; SALATHE, M. Using Deep Learning for Image-Based Plant Disease Detection. *Frontiers in Plant Science*, 2016. — Fonte do dataset PlantVillage e referência para segmentação de folhas via espaço de cor HSB.
- SINGH, V.; MISRA, A. K. Plant Disease Detection Using Image Processing and Machine Learning. *arXiv:2106.10698*, 2021. — Pipeline clássico com HSV, GLCM e contornos.

- Novel Algorithm for Semi-Automatic Segmentation of Plant Leaf Disease Symptoms Using Digital Image Processing. Academia.edu — Uso de histogramas dos canais H (HSV) e a (Lab) para separar tecidos doentes de saudáveis.

4. Pipeline de Execução

O sistema é composto por quatro estágios sequenciais, todos implementados em Python com OpenCV. Cada estágio recebe a saída do anterior e produz uma representação progressivamente mais refinada da informação da imagem.

Estágio 1 — Pré-processamento

Objetivo: preparar a imagem para as etapas subsequentes, corrigindo problemas de formato e reduzindo ruídos.

- `cv2.imread()` — Carregamento da imagem em formato BGR (padrão do OpenCV).
- `cv2.cvtColor(img, cv2.COLOR_BGR2RGB)` — Conversão para RGB para visualização correta com matplotlib.
- `cv2.cvtColor(img, cv2.COLOR_BGR2HSV)` — Conversão para HSV, espaço de cor principal da análise.
- `cv2.GaussianBlur()` — Suavização gaussiana para redução de ruído antes da segmentação.
- `cv2.resize()` — Redimensionamento para 256×256 pixels (padrão do PlantVillage).

Estágio 2 — Segmentação da Folha

Objetivo: isolar a folha do fundo da imagem, produzindo uma máscara binária que delimita a área total da folha.

- `cv2.inRange(hsv, lower_green, upper_green)` — Segmentação dos pixels verdes no espaço HSV para identificar o tecido foliar.
- `cv2.threshold()` com `cv2.THRESH_OTSU` — Limiarização automática de Otsu como método alternativo/complementar.
- `cv2.morphologyEx(mask, cv2.MORPH_CLOSE, kernel)` — Fechamento morfológico para preencher buracos na máscara da folha.
- `cv2.morphologyEx(mask, cv2.MORPH_OPEN, kernel)` — Abertura morfológica para remover ruídos pequenos fora da folha.
- `cv2.findContours()` + `cv2.contourArea()` — Identificação do maior contorno (a folha) e cálculo da sua área em pixels.
- `cv2.bitwise_and()` — Aplica a máscara sobre a imagem original para extrair apenas a região da folha.

Estágio 3 — Detecção das Lesões

Objetivo: dentro da área da folha segmentada, identificar os pixels que correspondem a regiões lesionadas.

- `cv2.inRange(hsv, lower_disease, upper_disease)` — Segmentação por faixa de cor das regiões doentes (H alvo: amarelos H 15–35, marrons H 0–15 e 160–179).

- `cv2.bitwise_and(disease_mask, leaf_mask)` — Garante que apenas lesões dentro da folha sejam contadas.
- `cv2.morphologyEx()` — Refina a máscara de lesão com operações de abertura e fechamento.
- `cv2.findContours()` — Identifica e delimita individualmente cada região lesionada.
- `cv2.drawContours()` — Desenha os contornos das lesões sobre a imagem original para visualização.

Estágio 4 — Análise Quantitativa e Classificação de Severidade

Objetivo: a partir das áreas calculadas, produzir uma métrica objetiva e uma classificação da gravidade da doença.

- Cálculo da porcentagem de área afetada: $(\text{pixels_lesao} / \text{pixels_folha}) \times 100$.
- Classificação por limiar fixo em quatro categorias: Saudável (< 5%), Leve (5–20%), Moderada (20–50%), Grave (> 50%).
- `cv2.calcHist()` — Cálculo do histograma do canal H nas regiões doentes vs. saudáveis.
- `matplotlib.pyplot` — Visualização final: imagem original | máscara da folha | máscara de lesão | histograma.

5. Dataset

5.1 PlantVillage

O dataset utilizado será o PlantVillage, introduzido por Mohanty et al. (2016) e amplamente adotado como benchmark na área de detecção de doenças em plantas.

- 54.303 imagens de folhas, rotuladas por espécie e doença.
- 38 classes (pares cultura–doença), cobrindo 14 espécies: tomate, batata, maçã, uva, milho, entre outras.
- Três versões disponíveis: colorida (RGB), escala de cinza e já segmentada. Será utilizada a versão colorida.
- Imagens coletadas em condições controladas de laboratório, com fundo uniforme — ideal para o pipeline proposto.
- Disponibilidade: público e gratuito. Repositório: github.com/spMohanty/PlantVillage-Dataset

5.2 Estratégia de Uso

Para o escopo deste projeto, não será utilizado o dataset completo. A estratégia é:

- Selecionar 2 a 3 espécies de plantas (tomate e batata, por terem muitas classes de doença bem distintas).
- Para cada espécie, usar a classe “saudável” e ao menos 2 classes de doenças.
- Trabalhar com um subconjunto de 50–100 imagens por classe para desenvolvimento e validação visual.
- A análise quantitativa (porcentagem de área afetada) será o principal critério de avaliação.

6. Ferramentas e Ambiente

Ferramenta	Versão Recomendada	Função no Projeto
Python	3.10+	Linguagem principal
OpenCV (cv2)	4.x	Todas as operações de PI
NumPy	1.24+	Operações sobre arrays de pixels
Matplotlib	3.7+	Visualização e histogramas
Jupyter Notebook	Qualquer	Ambiente de desenvolvimento interativo

Não é necessário GPU. Todo o pipeline roda em CPU comum. O ambiente pode ser configurado localmente ou via Google Colab (gratuito), que já possui todas as bibliotecas instaladas por padrão.

7. Cronograma de Execução

Período total: 05/05/2026 a 06/07/2026 — 9 semanas.

Semana	Período	Atividades	Entregável
1	05/05 – 11/05	Configuração do ambiente, download do dataset, leitura dos artigos	Ambiente pronto + dataset local
2	12/05 – 18/05	Estágio 1: pré-processamento, carregamento e conversão de espaço de cor	Notebook: Pré-processamento
3	19/05 – 25/05	Estágio 2: segmentação da folha com HSV + morfologia	Notebook: Segmentação da Folha
4	26/05 – 01/06	Ajuste dos parâmetros HSV e validação visual	Máscara da folha funcionando
5	02/06 – 08/06	Estágio 3: detecção das lesões e refinação morfológica	Notebook: Detecção de Lesões
6	09/06 – 15/06	Estágio 4: cálculo de área, severidade e histogramas	Pipeline completo e integrado
7	16/06 – 22/06	Testes com imagens variadas, análise dos casos com erro	Resultados e discussão
8	23/06 – 29/06	Elaboração do relatório final e organização dos notebooks	Relatório final (rascunho)
9	30/06 – 06/07	Revisão final, correções e entrega	Entrega — 06/07/2026

8. Resultados Esperados

8.1 Entregas Concretas

- Notebook Jupyter com o pipeline completo, bem comentado e organizado por estágios.
- Conjunto de visualizações: para cada imagem analisada, exibir a imagem original, a máscara da folha, a máscara das lesões e o histograma de cor.
- Tabela de resultados: para cada imagem testada, registrar a área total da folha (px), área lesionada (px), percentual afetado e classificação de severidade.
- Relatório final descrevendo as decisões de projeto, parâmetros escolhidos e análise dos resultados.

8.2 Critérios de Classificação de Severidade

Nível	Área Afetada	Interpretação
Saudável	< 5%	Folha sem lesões significativas
Leve	5% – 20%	Presença de manchas isoladas, início de infecção
Moderada	20% – 50%	Infecção em progressão, intervenção recomendada
Grave	> 50%	Grande parte da folha comprometida

8.3 Limitações Conhecidas

O projeto reconhece as seguintes limitações inerentes à abordagem clássica:

- O pipeline é otimizado para imagens em fundo uniforme (condições controladas do PlantVillage). Imagens em campo aberto exigiriam ajustes adicionais.
- Os limiares HSV para detecção de lesões são definidos manualmente e podem não generalizar perfeitamente para todas as doenças e espécies.
- O sistema não identifica qual doença especificamente está presente, apenas a presença e severidade das lesões.
- Doenças que não alteram a cor da folha (ex: doenças estruturais) não seriam detectadas por este método.